

파이썬데이터분석



데이터사이언스 전공

담당교수: 서지훈



강남대학교

2. 파이썬 데이터 다루기

2.24 stack과 unstack

- **stack** 함수는 특정 열을 그룹화하여 행 단위로 표시하고 계산한 데이터를 나타냄
- **unstack** 함수는 열 단위로 표시하고 계산한 데이터를 나타냄
 - 지정한 열을 기준으로 모든 열 값을 풀어서 출력할 때 사용

[stack]

시도명	일자	값	
서귀포시	2018년	거주인구(명)	183437.5044
		방문인구(명)	136493.7039
	2019년	거주인구(명)	195625.3659
		방문인구(명)	142424.3788
	2020년	거주인구(명)	222758.3904
		방문인구(명)	117197.1859
제주시	2018년	거주인구(명)	400738.593
		방문인구(명)	237845.2388
	2019년	거주인구(명)	395796.5919
		방문인구(명)	244563.1351
	2020년	거주인구(명)	407192.6644
		방문인구(명)	205097.9053

[unstack]

시도명	일자	거주인구(명)	방문인구(명)
서귀포시	2018년	183437.5044	136493.7039
	2019년	195625.3659	142424.3788
	2020년	222758.3904	117197.1859
제주시	2018년	400738.593	237845.2388
	2019년	395796.5919	244563.1351
	2020년	407192.6644	205097.9053

stack

←·····

unstack

·····→

2. 파이썬 데이터 다루기

2.24 stack과 unstack

✓ 실행 코드

```
df = titanic_df.groupby(['sex', 'survived']).mean()  
df
```

		passengerId	pclass	age	sibsp	parch	fare
sex	survived						
female	0	80.437500	2.937500	20.633333	1.437500	0.562500	18.883331
	1	63.200000	2.275000	26.265625	0.650000	0.500000	32.291563
male	0	85.639535	2.406977	31.228571	0.523256	0.337209	28.831587
	1	76.142857	2.357143	23.314444	0.142857	0.285714	22.270236

2. 파이썬 데이터 다루기

2.24 stack과 unstack

✓ 실행 코드

```
df.unstack('sex')
```

	passengerId		pclass		age		sibsp		parch		fare	
sex	female	male	female	male	female	male	female	male	female	male	female	male
survived												
0	80.4375	85.639535	2.9375	2.406977	20.633333	31.228571	1.4375	0.523256	0.5625	0.337209	18.883331	28.831587
1	63.2000	76.142857	2.2750	2.357143	26.265625	23.314444	0.6500	0.142857	0.5000	0.285714	32.291563	22.270236

✓ 실행 코드

```
df.unstack('survived')
```

	passengerId		pclass		age		sibsp		parch		fare	
survived	0	1	0	1	0	1	0	1	0	1	0	1
sex												
female	80.437500	63.200000	2.937500	2.275000	20.633333	26.265625	1.437500	0.650000	0.562500	0.500000	18.883331	32.291563
male	85.639535	76.142857	2.406977	2.357143	31.228571	23.314444	0.523256	0.142857	0.337209	0.285714	28.831587	22.270236

2. 파이썬 데이터 다루기

2.24 stack과 unstack

✓ 실행 코드

```
survived=df.unstack('survived')  
survived_stack=survived.stack('survived')  
survived_stack
```

		passengerId	pclass	age	sibsp	parch	fare
sex	survived						
female	0	80.437500	2.937500	20.633333	1.437500	0.562500	18.883331
	1	63.200000	2.275000	26.265625	0.650000	0.500000	32.291563
male	0	85.639535	2.406977	31.228571	0.523256	0.337209	28.831587
	1	76.142857	2.357143	23.314444	0.142857	0.285714	22.270236

2. 파이썬 데이터 다루기

2.25 인덱스 초기화하기: reset_index 함수

- reset_index 함수는 멀티 인덱스로 구성된 데이터프레임의 인덱스 초기화에 사용
- 옵션을 inplace=True로 지정하면 데이터프레임명을 따로 지정하지 않고 원본 자체를 초기화 함

✓ 실행 코드

```
df1=df.reset_index( )  
df1
```

	sex	survived	passengerId	pclass	age	sibsp	parch	fare
0	female	0	80.437500	2.937500	20.633333	1.437500	0.562500	18.883331
1	female	1	63.200000	2.275000	26.265625	0.650000	0.500000	32.291563
2	male	0	85.639535	2.406977	31.228571	0.523256	0.337209	28.831587
3	male	1	76.142857	2.357143	23.314444	0.142857	0.285714	22.270236

2. 파이썬 데이터 다루기

2.25 인덱스 초기화하기: reset_index 함수

✓ 실행 코드

```
df.reset_index(inplace=True)  
df
```

	sex	survived	passengerId	pclass	age	sibsp	parch	fare
0	female	0	80.437500	2.937500	20.633333	1.437500	0.562500	18.883331
1	female	1	63.200000	2.275000	26.265625	0.650000	0.500000	32.291563
2	male	0	85.639535	2.406977	31.228571	0.523256	0.337209	28.831587
3	male	1	76.142857	2.357143	23.314444	0.142857	0.285714	22.270236

2. 파이썬 데이터 다루기

2.26 데이터 합치기: concat 함수

- concat 함수는 행의 인덱스와 열의 크기에 상관없이 위아래 혹은 옆으로 데이터를 합칠 때 사용
- 옵션을 지정하지 않으면 기본값으로 axis=0이 적용되어 위아래로 합치게 됨

✓ 실행 코드

```
import pandas as pd
url='https://github.com/sehakflower/data/blob/main/titanic_1309.xlsx?raw=true'
titanic=pd.read_excel(url, sheet_name='total')
titanic
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
0	1	1	Allen, Miss. Elisabeth Walton	female	29.0000	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	Allison, Master. Hudson Trevor	male	0.9167	1	2	113781	151.5500	C22 C26	S	11	NaN	Montreal, PQ / Chesterville, ON
2	1	0	Allison, Miss. Helen Loraine	female	2.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1	2	113781	151.5500	C22 C26	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1304	3	0	Zabour, Miss. Hileni	female	14.5000	1	0	2665	14.4542	NaN	C	NaN	328.0	NaN
1305	3	0	Zabour, Miss. Thamine	female	NaN	1	0	2665	14.4542	NaN	C	NaN	NaN	NaN
1306	3	0	Zakarian, Mr. Mapriededer	male	26.5000	0	0	2656	7.2250	NaN	C	NaN	304.0	NaN
1307	3	0	Zakarian, Mr. Ortin	male	27.0000	0	0	2670	7.2250	NaN	C	NaN	NaN	NaN
1308	3	0	Zimmerman, Mr. Leo	male	29.0000	0	0	315082	7.8750	NaN	S	NaN	NaN	NaN

1309 rows × 14 columns

2. 파이썬 데이터 다루기

2.26 데이터 합치기: concat 함수

✓ 실행 코드

```
train_1000=titanic.iloc[:1000]  
test_309=titanic.iloc[1000:]  
len(train_1000), len(test_309)
```


```
(1000, 309)
```

✓ 실행 코드

```
train_1000.to_csv('train_1000.csv')  
test_309.to_csv('test_309.csv')
```

```
pwd
```

```
/content
```



2. 파이썬 데이터 다루기

2.26 데이터 합치기: concat 함수

✓ 실행 코드

```
ls
```

```
file.txt hello.txt proverb.txt sample_data/ test_309.csv train_1000.csv
```

✓ 실행 코드

```
pd.read_csv('train_1000.csv')
```

Unnamed: 0	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest	
0	0	1	1	Allen, Miss. Elisabeth Walton	female	29.0000	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	1	Allison, Master. Hudson Trevor	male	0.9167	1	2	113781	151.5500	C22 C26	S	11	NaN	Montreal, PQ / Chesterville, ON
2	2	1	0	Allison, Miss. Helen Loraine	female	2.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1	2	113781	151.5500	C22 C26	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
995	995	3	0	Markoff, Mr. Marin	male	35.0000	0	0	349213	7.8958	NaN	C	NaN	NaN	NaN
996	996	3	0	Markun, Mr. Johann	male	33.0000	0	0	349257	7.8958	NaN	S	NaN	NaN	NaN
997	997	3	1	Masselmani, Mrs. Fatima	female	NaN	0	0	2649	7.2250	NaN	C	C	NaN	NaN
998	998	3	0	Matinoff, Mr. Nicola	male	NaN	0	0	349255	7.8958	NaN	C	NaN	NaN	NaN
999	999	3	1	McCarthy, Miss. Catherine "Katie"	female	NaN	0	0	383123	7.7500	NaN	Q	15 16	NaN	NaN

1000 rows × 15 columns

2. 파이썬 데이터 다루기

2.26 데이터 합치기: concat 함수

✓ 실행 코드

```
total_df=pd.concat([train_1000, test_309]) # 옵션 없으면 axis=0

total_df=pd.concat([train_1000, test_309], axis=0) # 위아래로 붙일 때는 axis=0

total_df
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
0	1	1	Allen, Miss. Elisabeth Walton	female	29.0000	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	Allison, Master. Hudson Trevor	male	0.9167	1	2	113781	151.5500	C22 C26	S	11	NaN	Montreal, PQ / Chesterville, ON
2	1	0	Allison, Miss. Helen Loraine	female	2.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1	2	113781	151.5500	C22 C26	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1304	3	0	Zabour, Miss. Hileni	female	14.5000	1	0	2665	14.4542	NaN	C	NaN	328.0	NaN
1305	3	0	Zabour, Miss. Thamine	female	NaN	1	0	2665	14.4542	NaN	C	NaN	NaN	NaN
1306	3	0	Zakarian, Mr. Mapriededer	male	26.5000	0	0	2656	7.2250	NaN	C	NaN	304.0	NaN
1307	3	0	Zakarian, Mr. Ortin	male	27.0000	0	0	2670	7.2250	NaN	C	NaN	NaN	NaN
1308	3	0	Zimmerman, Mr. Leo	male	29.0000	0	0	315082	7.8750	NaN	S	NaN	NaN	NaN

1309 rows × 14 columns

2. 파이썬 데이터 다루기

2.26 데이터 합치기: concat 함수

✓ 실행 코드

```
total_df=pd.concat([train_1000, test_309])
total_df=pd.concat([train_1000, test_309], axis=1)
total_df
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	...	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
0	1.0	1.0	Allen, Miss. Elisabeth Walton	female	29.0000	0.0	0.0	24160	211.3375	B5	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	1.0	1.0	Allison, Master. Hudson Trevor	male	0.9167	1.0	2.0	113781	151.5500	C22 C26	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	1.0	0.0	Allison, Miss. Helen Loraine	female	2.0000	1.0	2.0	113781	151.5500	C22 C26	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	1.0	0.0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1.0	2.0	113781	151.5500	C22 C26	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	1.0	0.0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1.0	2.0	113781	151.5500	C22 C26	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1304	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	14.5	1.0	0.0	2665	14.4542	NaN	C	NaN	328.0	NaN
1305	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	1.0	0.0	2665	14.4542	NaN	C	NaN	NaN	NaN
1306	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	26.5	0.0	0.0	2656	7.2250	NaN	C	NaN	304.0	NaN
1307	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	27.0	0.0	0.0	2670	7.2250	NaN	C	NaN	NaN	NaN
1308	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	29.0	0.0	0.0	315082	7.8750	NaN	S	NaN	NaN	NaN

1309 rows × 28 columns

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

- merge 함수는 두 개의 데이터프레임을 고유값(key)를 갖는 열을 기준으로 병합할 때 사용
- 옵션 기본값은 `pd.merge(df_left, df_right, how='inner', on=None)`

✓ 실행 코드

```
df1=train_1000[['name', 'pclass', 'sex', 'age']]
df1
```

	name	pclass	sex	age
0	Allen, Miss. Elisabeth Walton	1	female	29.0000
1	Allison, Master. Hudson Trevor	1	male	0.9167
2	Allison, Miss. Helen Loraine	1	female	2.0000
3	Allison, Mr. Hudson Joshua Creighton	1	male	30.0000
4	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0000
...	...	...	...	...
995	Markoff, Mr. Marin	3	male	35.0000
996	Markun, Mr. Johann	3	male	33.0000
997	Masselmani, Mrs. Fatima	3	female	NaN
998	Matinoff, Mr. Nicola	3	male	NaN
999	McCarthy, Miss. Catherine "Katie"	3	female	NaN

1000 rows × 4 columns

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

✓ 실행 코드

```
df2=train_1000[['name', 'survived']]  
df2
```

	name	survived
0	Allen, Miss. Elisabeth Walton	1
1	Allison, Master. Hudson Trevor	1
2	Allison, Miss. Helen Loraine	0
3	Allison, Mr. Hudson Joshua Creighton	0
4	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	0
...	...	...
995	Markoff, Mr. Marin	0
996	Markun, Mr. Johann	0
997	Masselmani, Mrs. Fatima	1
998	Matinoff, Mr. Nicola	0
999	McCarthy, Miss. Catherine "Katie"	1

1000 rows × 2 columns

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

✓ 실행 코드

```
merge_inner=pd.merge(df1, df2)
merge_inner
```

	name	pclass	sex	age	survived
0	Allen, Miss. Elisabeth Walton	1	female	29.0000	1
1	Allison, Master. Hudson Trevor	1	male	0.9167	1
2	Allison, Miss. Helen Loraine	1	female	2.0000	0
3	Allison, Mr. Hudson Joshua Creighton	1	male	30.0000	0
4	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0000	0
...	...	...	...	...	...
999	Markoff, Mr. Marin	3	male	35.0000	0
1000	Markun, Mr. Johann	3	male	33.0000	0
1001	Masselmani, Mrs. Fatima	3	female	NaN	1
1002	Matinoff, Mr. Nicola	3	male	NaN	0
1003	McCarthy, Miss. Catherine "Katie"	3	female	NaN	1

1004 rows × 5 columns

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

✓ 실행 코드

```
df2.loc[[0,2,3], ['name']] = ''  
df2=df2[:10]  
df1=df1[:10]  
merge_inner=pd.merge(df1, df2, how='inner', on='name')  
merge_inner
```

	name	pclass	sex	age	survived
0	Allison, Master. Hudson Trevor	1	male	0.9167	1
1	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0000	0
2	Anderson, Mr. Harry	1	male	48.0000	1
3	Andrews, Miss. Kornelia Theodosia	1	female	63.0000	1
4	Andrews, Mr. Thomas Jr	1	male	39.0000	0
5	Appleton, Mrs. Edward Dale (Charlotte Lamson)	1	female	53.0000	1
6	Artagaveytia, Mr. Ramon	1	male	71.0000	0

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

✓ 실행 코드

```
merge_outer = pd.merge(df1, df2, how='outer', on='name')  
merge_outer
```

	name	pclass	sex	age	survived
0		NaN	NaN	NaN	1.0
1		NaN	NaN	NaN	0.0
2		NaN	NaN	NaN	0.0
3	Allen, Miss. Elisabeth Walton	1.0	female	29.0000	NaN
4	Allison, Master. Hudson Trevor	1.0	male	0.9167	1.0
5	Allison, Miss. Helen Loraine	1.0	female	2.0000	NaN
6	Allison, Mr. Hudson Joshua Creighton	1.0	male	30.0000	NaN
7	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1.0	female	25.0000	0.0
8	Anderson, Mr. Harry	1.0	male	48.0000	1.0
9	Andrews, Miss. Kornelia Theodosia	1.0	female	63.0000	1.0
10	Andrews, Mr. Thomas Jr	1.0	male	39.0000	0.0
11	Appleton, Mrs. Edward Dale (Charlotte Lamson)	1.0	female	53.0000	1.0
12	Artagaveytia, Mr. Ramon	1.0	male	71.0000	0.0

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

✓ 실행 코드

```
merge_left=pd.merge(df1, df2, how='left', left_on='name',  
right_on='name')  
merge_left
```

	name	pclass	sex	age	survived
0	Allen, Miss. Elisabeth Walton	1	female	29.0000	NaN
1	Allison, Master. Hudson Trevor	1	male	0.9167	1.0
2	Allison, Miss. Helen Loraine	1	female	2.0000	NaN
3	Allison, Mr. Hudson Joshua Creighton	1	male	30.0000	NaN
4	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0000	0.0
5	Anderson, Mr. Harry	1	male	48.0000	1.0
6	Andrews, Miss. Kornelia Theodosia	1	female	63.0000	1.0
7	Andrews, Mr. Thomas Jr	1	male	39.0000	0.0
8	Appleton, Mrs. Edward Dale (Charlotte Lamson)	1	female	53.0000	1.0
9	Artagaveytia, Mr. Ramon	1	male	71.0000	0.0

2. 파이썬 데이터 다루기

2.27 데이터프레임 병합: merge 함수

✓ 실행 코드

```
merge_right=pd.merge(df1, df2, how='right', left_on='name',  
right_on='name')  
merge_right
```

	name	pclass	sex	age	survived
0		NaN	NaN	NaN	1
1	Allison, Master. Hudson Trevor	1.0	male	0.9167	1
2		NaN	NaN	NaN	0
3		NaN	NaN	NaN	0
4	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1.0	female	25.0000	0
5	Anderson, Mr. Harry	1.0	male	48.0000	1
6	Andrews, Miss. Kornelia Theodosia	1.0	female	63.0000	1
7	Andrews, Mr. Thomas Jr	1.0	male	39.0000	0
8	Appleton, Mrs. Edward Dale (Charlotte Lamson)	1.0	female	53.0000	1
9	Artagaveytia, Mr. Ramon	1.0	male	71.0000	0

2. 파이썬 데이터 다루기

2.28 데이터프레임 결합: join 함수

- join 함수는 merge 함수와 작동 방식이 비슷함
- 차이점은 join 함수는 행 인덱스를 기준으로, merge 함수는 특정 열 기준으로 결합 함

✓ 실행 코드

```
df2.loc[[1], ['name']] = 'Kildong, Mr. Hong'
df2 = df2[:10]
df2
```

	name	survived
0		1
1	Kildong, Mr. Hong	1
2		0
3		0
4	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	0
5	Anderson, Mr. Harry	1
6	Andrews, Miss. Kornelia Theodosia	1
7	Andrews, Mr. Thomas Jr	0
8	Appleton, Mrs. Edward Dale (Charlotte Lamson)	1
9	Artagaveytia, Mr. Ramon	0

2. 파이썬 데이터 다루기

2.28 데이터프레임 결합: join 함수

✓ 실행 코드

```
df1.set_index('name', inplace=True)
df2.set_index('name', inplace=True)
df1
```

	pclass	sex	age
name			
Allen, Miss. Elisabeth Walton	1	female	29.0000
Allison, Master. Hudson Trevor	1	male	0.9167
Allison, Miss. Helen Loraine	1	female	2.0000
Allison, Mr. Hudson Joshua Creighton	1	male	30.0000
Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0000
Anderson, Mr. Harry	1	male	48.0000
Andrews, Miss. Kornelia Theodosia	1	female	63.0000
Andrews, Mr. Thomas Jr	1	male	39.0000
Appleton, Mrs. Edward Dale (Charlotte Lamson)	1	female	53.0000
Artagaveytia, Mr. Ramon	1	male	71.0000

2. 파이썬 데이터 다루기

2.28 데이터프레임 결합: join 함수

✓ 실행 코드

```
df2
```

survived	name
1	
1	Kildong, Mr. Hong
0	
0	
0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)
1	Anderson, Mr. Harry
1	Andrews, Miss. Kornelia Theodosia
0	Andrews, Mr. Thomas Jr
1	Appleton, Mrs. Edward Dale (Charlotte Lamson)
0	Artagaveytia, Mr. Ramon

2. 파이썬 데이터 다루기

2.28 데이터프레임 결합: join 함수

✓ 실행 코드

```
df1.join(df2)
```

	pclass	sex	age	survived
name				
Allen, Miss. Elisabeth Walton	1	female	29.0000	NaN
Allison, Master. Hudson Trevor	1	male	0.9167	NaN
Allison, Miss. Helen Loraine	1	female	2.0000	NaN
Allison, Mr. Hudson Joshua Creighton	1	male	30.0000	NaN
Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0000	0.0
Anderson, Mr. Harry	1	male	48.0000	1.0
Andrews, Miss. Kornelia Theodosia	1	female	63.0000	1.0
Andrews, Mr. Thomas Jr	1	male	39.0000	0.0
Appleton, Mrs. Edward Dale (Charlotte Lamson)	1	female	53.0000	1.0
Artagaveytia, Mr. Ramon	1	male	71.0000	0.0

2. 파이썬 데이터 다루기

2.28 데이터프레임 결합: join 함수

✓ 실행 코드

```
df1.join(df2, how='inner')
```

	pclass	sex	age	survived
name				
Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	1	female	25.0	0
Anderson, Mr. Harry	1	male	48.0	1
Andrews, Miss. Kornelia Theodosia	1	female	63.0	1
Andrews, Mr. Thomas Jr	1	male	39.0	0
Appleton, Mrs. Edward Dale (Charlotte Lamson)	1	female	53.0	1
Artagaveytia, Mr. Ramon	1	male	71.0	0

2. 파이썬 데이터 다루기

2.28 데이터프레임 결합: join 함수

✓ 실행 코드

```
df2.join(df1)
```

	survived	pclass	sex	age
name				
	1	NaN	NaN	NaN
Kildong, Mr. Hong	1	NaN	NaN	NaN
	0	NaN	NaN	NaN
	0	NaN	NaN	NaN
Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	0	1.0	female	25.0
Anderson, Mr. Harry	1	1.0	male	48.0
Andrews, Miss. Kornelia Theodosia	1	1.0	female	63.0
Andrews, Mr. Thomas Jr	0	1.0	male	39.0
Appleton, Mrs. Edward Dale (Charlotte Lamson)	1	1.0	female	53.0
Artagaveytia, Mr. Ramon	0	1.0	male	71.0

2. 파이썬 데이터 다루기

2.29 불 인덱스(Boolean Index)

- 특정 열을 대상으로 조건을 주고 원하는 데이터를 가져올 수 있음
- 주어진 조건에 따라 True와 False에 해당하는 값을 추출할 수 있음
- True 또는 False 데이터를 골라서 사용할 수 있음
- 추출할 열 이름을 맨 뒤에 추가하면 특정 열만 추출 가능

✓ 실행 코드

```
titanic_df[titanic_df['age']>70] # 70세 이상인 승객 검색
```

	passengerId	survived	pclass	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
96	97	0	1	Goldschmidt, Mr. George B	male	71.0	0	0	PC 17754	34.6542	A5	C
116	117	0	3	Connors, Mr. Patrick	male	70.5	0	0	370369	7.7500	NaN	Q

2. 파이썬 데이터 다루기

2.29 불 인덱스(Boolean Index)

✓ 실행 코드

```
titanic_df[titanic_df['age']<3] # 3세 미만인 승객 검색
```

	passengerId	survived	pclass	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
7	8	0	3	Palsson, Master. Gosta Leonard	male	2.00	3	1	349909	21.075	NaN	S
16	17	0	3	Rice, Master. Eugene	male	2.00	4	1	382652	29.125	NaN	Q
78	79	1	2	Caldwell, Master. Alden Gates	male	0.83	0	2	248738	29.000	NaN	S
119	120	0	3	Andersson, Miss. Ellis Anna Maria	female	2.00	4	2	347082	31.275	NaN	S

2. 파이썬 데이터 다루기

2.29 불 인덱스(Boolean Index)

✓ 실행 코드

```
titanic_df[titanic_df['age']<3]['name'] # 3세 미만 승객의 이름 검색
```

	name
7	Palsson, Master. Gosta Leonard
16	Rice, Master. Eugene
78	Caldwell, Master. Alden Gates
119	Andersson, Miss. Ellis Anna Maria
dtype: object	

2. 파이썬 데이터 다루기

2.29 불 인덱스(Boolean Index)

✓ 실행 코드

```
titanic_df[titanic_df['age']<3][['age', 'name']]
```

	age	name
7	2.00	Palsson, Master. Gosta Leonard
16	2.00	Rice, Master. Eugene
78	0.83	Caldwell, Master. Alden Gates
119	2.00	Andersson, Miss. Ellis Anna Maria

2. 파이썬 데이터 다루기

2.30 loc 속성

- loc 속성으로 조건을 설정하여 필요한 열만 가져와 표시할 수 있음
- 데이터프레임.loc[데이터프레임['열 이름']]을 이용한 조건식][표시할 열 이름]
- - 조건식과 열 이름을 쉼표를 이용하여 함께 나타내기도 함
- - 콜론으로 열 범위를 나타낼 수 있음
- - 열 이름을 리스트 형태로 입력해도 됨

✓ 실행 코드

```
titanic_df.loc[titanic_df['age']<3]['name']  
# 3세 미만 승객의 이름 검색
```

	name
7	Palsson, Master. Gosta Leonard
16	Rice, Master. Eugene
78	Caldwell, Master. Alden Gates
119	Andersson, Miss. Ellis Anna Maria
dtype: object	

2. 파이썬 데이터 다루기

2.30 loc 속성

✓ 실행 코드

```
titanic_df.loc[titanic_df['age']<3, 'name':'sex']
```

	name	sex
7	Palsson, Master. Gosta Leonard	male
16	Rice, Master. Eugene	male
78	Caldwell, Master. Alden Gates	male
119	Andersson, Miss. Ellis Anna Maria	female

2. 파이썬 데이터 다루기

2.30 loc 속성

✓ 실행 코드

```
titanic_df.loc[titanic_df['age']<3, ['name', 'sex']]
```

	name	sex
7	Palsson, Master. Gosta Leonard	male
16	Rice, Master. Eugene	male
78	Caldwell, Master. Alden Gates	male
119	Andersson, Miss. Ellis Anna Maria	female

2. 파이썬 데이터 다루기

2.31 isin 함수

- 열에 어떤 데이터가 존재하는지 검색할 때 사용
- 데이터가 존재하면 True, 없으면 False를 반환
- 조건으로 검색하려는 값이 해당 리스트에 있을 때만 사용
- 조건으로 사용할 데이터를 리스트 형태로 만들고, 데이터프레임 이름[열 이름].isin(리스트 이름) 형태로 설정

✓ 실행 코드

```
my_condition=['male']  
my_condition
```

```
['male']
```

2. 파이썬 데이터 다루기

2.31 isin 함수

✓ 실행 코드

```
titanic_df['sex'].isin(my_condition)
```

sex	
0	True
1	False
2	False
3	False
4	True
...	...
151	False
152	True
153	True
154	True
155	True

156 rows × 1 columns

dtype: bool

2. 파이썬 데이터 다루기

2.31 isin 함수

✓ 실행 코드

```
titanic_df['name']
```

	name
0	Braund, Mr. Owen Harris
1	Cumings, Mrs. John Bradley (Florence Briggs Th...
2	Heikkinen, Miss. Laina
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)
4	Allen, Mr. William Henry
...	...
151	Pears, Mrs. Thomas (Edith Wearne)
152	Meo, Mr. Alfonzo
153	van Billiard, Mr. Austin Blyler
154	Olsen, Mr. Ole Martin
155	Williams, Mr. Charles Duane

156 rows × 1 columns

dtype: object

2. 파이썬 데이터 다루기

2.31 isin 함수

✓ 실행 코드

```
my_condition1=['Braund, Mr. Owen Harris', 'Williams, Mr.  
Charles Duane']  
my_condition1
```

```
['Braund, Mr. Owen Harris', 'Williams, Mr. Charles Duane']
```

2. 파이썬 데이터 다루기

2.31 isin 함수

✓ 실행 코드

```
titanic_df['name'].isin(my_condition1)
```

	name
0	True
1	False
2	False
3	False
4	False
...	...
151	False
152	False
153	False
154	False
155	True

156 rows × 1 columns

dtype: bool

2. 파이썬 데이터 다루기

2.32 True/False 반환하는 조건 활용하기

- (1) 데이터프레임 이름 뒤에 .loc를 입력
- (2) isin 함수를 사용하여 my_condition1 변수의 값으로 조건 설정
- (3) True인 경우 값이 추출됨
 - 조건에 해당하는 열만 표시하려면 마지막에 열 이름을 추가 설정
 - 열 이름 사이에 콜론을 입력하면 두 열 이름 사이에 포함된 열 표시
 - 열 이름 사이에 쉼표를 입력하면 각각의 열 표시

✓ 실행 코드

```
titanic_df.loc[titanic_df['name'].isin(my_condition1)]
```

	passengerId	survived	pclass	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
155	156	0	1	Williams, Mr. Charles Duane	male	51.0	0	1	PC 17597	61.3792	NaN	C

2. 파이썬 데이터 다루기

2.32 True/False 반환하는 조건 활용하기

✓ 실행 코드

```
titanic_df.loc[titanic_df['name'].isin(my_condition1), 'age']
```

	age
0	22.0
155	51.0
dtype: float64	

2. 파이썬 데이터 다루기

2.32 True/False 반환하는 조건 활용하기

✓ 실행 코드

```
titanic_df.loc[titanic_df['name'].isin(my_condition1), 'name']
```

name

0 Braund, Mr. Owen Harris

155 Williams, Mr. Charles Duane

dtype: object

2. 파이썬 데이터 다루기

2.32 True/False 반환하는 조건 활용하기

✓ 실행 코드

```
titanic_df.loc[titanic_df['name'].isin(my_condition1),  
               'pclass':'age']
```

	pclass	name	sex	age
0	3	Braund, Mr. Owen Harris	male	22.0
155	1	Williams, Mr. Charles Duane	male	51.0

2. 파이썬 데이터 다루기

2.32 True/False 반환하는 조건 활용하기

✓ 실행 코드

```
titanic_df.loc[titanic_df['name'].isin(my_condition1),  
               ['pclass', 'age']]
```

	pclass	age
0	3	22.0
155	1	51.0

- “검색 정보를 활용해 타이타닉 승객 구분하기”는 쉬운 항목들이므로 pt에는 포함하지 않습니다. 해당 부분은 자유롭게 실습을 권장합니다.

2. 파이썬 데이터 다루기

2.33 결측치 개념

- 데이터에 값이 없는 것
- 데이터를 수집하는 과정에서 오류나 실수로 발생
- 데이터 분석의 정확도를 높이기 위해서는 결측치를 삭제하거나 0 또는 평균값으로 채우는 것이 좋음

2.34 데이터프레임의 결측치 확인

- info 함수로 정보 확인
 - Non-Null은 결측치가 아닌 값을 의미, 나머지는 모두 결측치
 - 다스에서 object는 문자형, int64는 정수형, float64는 실수형을 의미

✓ 실행 코드

```
import pandas as pd
url='https://raw.githubusercontent.com/sehakflower/data/main/titanic.csv'
titanic_df= pd.read_csv(url, sep='\t')
titanic_df.info( )
```

2. 파이썬 데이터 다루기

2.35 isna 함수

- 결측치가 있는지 확인한 후 결측치가 있으면 NaN 반환
- 판다스에서 결측치를 NaN(Not a Number)으로 표시

✓ 실행 코드

```
titanic_df['age'][titanic_df['age'].isna( )]
```

	age
5	NaN
17	NaN
19	NaN
26	NaN
28	NaN
29	NaN
31	NaN
32	NaN
36	NaN
42	NaN
45	NaN
46	NaN
47	NaN
48	NaN
55	NaN
64	NaN



2. 파이썬 데이터 다루기

2.36 isnull 함수

- 결측치가 있는지 확인 후 결측치가 있으면 불 인덱스 True를 반환
- 결측치인 NaN 값만 추출할 수 있음
- sum 함수를 함께 사용하면 NaN 값이 총 몇 개인지 확인 가능

✓ 실행 코드

```
titanic_df['age'].isnull( )
```

age	
0	False
1	False
2	False
3	False
4	False
...	...
151	False
152	False
153	False
154	True
155	False
156 rows × 1 columns	
dtype: bool	

2. 파이썬 데이터 다루기

2.36 isnull 함수

✓ 실행 코드

```
titanic_df['age'][titanic_df['age'].isnull( )]
```

	age
5	NaN
17	NaN
19	NaN
26	NaN
28	NaN
29	NaN
31	NaN
32	NaN
36	NaN



2. 파이썬 데이터 다루기

2.36 isnull 함수

✓ 실행 코드

```
titanic_df['age'][titanic_df['age'].isnull( )].isnull( ).  
sum( )
```

```
np.int64(30)
```

2. 파이썬 데이터 다루기

2.37 notnull 함수

- 결측치가 있는지 확인한 후 결측치가 없으면 불 인덱스 True 반환
- 불 인덱스가 isnull 함수를 사용한 것과 서로 반대로 나타남

✓ 실행 코드

```
titanic_df['age'].notnull( )
```

	age
0	True
1	True
2	True
3	True
4	True
...	...
151	True
152	True
153	True
154	False
155	True

156 rows × 1 columns

dtype: bool

2. 파이썬 데이터 다루기

2.37 notnull 함수

✓ 실행 코드

```
titanic_df['age'][titanic_df['age'].notnull( )]
```

	age
0	22.0
1	38.0
2	26.0
3	35.0
4	35.0
...	...
150	51.0
151	22.0
152	55.5
153	40.5
155	51.0

126 rows × 1 columns

dtype: float64

2. 파이썬 데이터 다루기

2.37 notnull 함수

✓ 실행 코드

```
titanic_df.loc[titanic_df['age'].notnull( ), ['age', 'name']]
```

	age	name
0	22.0	Braund, Mr. Owen Harris
1	38.0	Cumings, Mrs. John Bradley (Florence Briggs Th...
2	26.0	Heikkinen, Miss. Laina
3	35.0	Futrelle, Mrs. Jacques Heath (Lily May Peel)
4	35.0	Allen, Mr. William Henry
...	...	...
150	51.0	Bateman, Rev. Robert James
151	22.0	Pears, Mrs. Thomas (Edith Wearne)
152	55.5	Meo, Mr. Alfonzo
153	40.5	van Billiard, Mr. Austin Blyler
155	51.0	Williams, Mr. Charles Duane

126 rows × 2 columns

2. 파이썬 데이터 다루기

2.37 notnull 함수

✓ 실행 코드

```
titanic_df.loc[titanic_df['age'].isnull( ), ['age', 'name']]
```

	age	name
5	NaN	Moran, Mr. James
17	NaN	Williams, Mr. Charles Eugene
19	NaN	Masselmani, Mrs. Fatima
26	NaN	Emir, Mr. Farred Chehab
28	NaN	O'Dwyer, Miss. Ellen "Nellie"
29	NaN	Todoroff, Mr. Lalio
31	NaN	Spencer, Mrs. William Augustus (Marie Eugenie)
32	NaN	Glynn, Miss. Mary Agatha
36	NaN	Mamee, Mr. Hanna
42	NaN	Kraeff, Mr. Theodor
45	NaN	Rogers, Mr. William John



2. 파이썬 데이터 다루기

2.38 결측치를 다른 문자로 변경하기

- fillna 함수를 사용하여 결측치 값을 변경
- count 함수를 사용하면 특정 열에서 개별 값이 모두 몇 개인지 확인 가능

✓ 실행 코드

```
titanic_df.head( )
```

	passengerId	survived	pclass	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

2. 파이썬 데이터 다루기

2.38 결측치를 다른 문자로 변경하기

✓ 실행 코드

```
titanic_df['cabin']=titanic_df['cabin'].fillna('N')  
titanic_df['cabin']
```

	cabin
0	N
1	C85
2	N
3	C123
4	N
...	...
151	C2
152	N
153	N
154	N
155	N

156 rows × 1 columns

dtype: object

2. 파이썬 데이터 다루기

2.38 결측치를 다른 문자로 변경하기

✓ 실행 코드

```
titanic_df['cabin'].value_counts( )
```

cabin	count
N	125
C123	2
C23 C25 C27	2
D26	2
E46	1
G6	1
C103	1
D56	1



2. 파이썬 데이터 다루기

2.38 결측치를 다른 문자로 변경하기

✓ 실행 코드

```
titanic_df['cabin'][0]
```

'N'

```
titanic_df['cabin']=titanic_df['cabin'].apply(lambda x : x[0])  
titanic_df['cabin']
```

cabin	
0	N
1	C
2	N
3	C
4	N
...	...
151	C
152	N
153	N
154	N
155	N

156 rows × 1 columns

dtype: object

2. 파이썬 데이터 다루기

2.38 결측치를 다른 문자로 변경하기

✓ 실행 코드

```
titanic_df.info( )
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 156 entries, 0 to 155
Data columns (total 12 columns):
 #   Column      Non-Null Count  Dtype  
---  -
 0   passengerId 156 non-null   int64  
 1   survived    156 non-null   int64  
 2   pclass      156 non-null   int64  
 3   name        156 non-null   object  
 4   sex         156 non-null   object  
 5   age         126 non-null   float64 
 6   sibsp       156 non-null   int64  
 7   parch       156 non-null   int64  
 8   ticket      156 non-null   object  
 9   fare        156 non-null   float64 
10   cabin       156 non-null   object  
11   embarked    155 non-null   object  
dtypes: float64(2), int64(5), object(5)
memory usage: 14.8+ KB
```


2. 파이썬 데이터 다루기

2.39 결측치를 평균값으로 변경하기

- `mean` 함수를 사용하여 특정 열의 평균값 구함
- `fillna` 함수를 사용하여 해당 열의 평균값으로 변경 가능
- 결측치인 경우에만 평균값으로 변경되고, 결측치가 아니면 원래 값 표시

✓ 실행 코드

```
titanic_df_copy=titanic_df.copy( )  
titanic_df_copy
```

passengerId	survived	pclass			name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
0	1	0	3		Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	N	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0		PC 17599	71.2833	C	C
2	3	1	3		Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	N	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0		113803	53.1000	C	S
4	5	0	3		Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	N	S
...	...	...	...		...	...	...	...	...	...	...	...	...
151	152	1	1	Pears, Mrs. Thomas (Edith Wearne)	female	22.0	1	0		113776	66.6000	C	S
152	153	0	3		Meo, Mr. Alfonzo	male	55.5	0	0	A.5. 11206	8.0500	N	S
153	154	0	3		van Billiard, Mr. Austin Blyler	male	40.5	0	2	A/5. 851	14.5000	N	S
154	155	0	3		Olsen, Mr. Ole Martin	male	NaN	0	0	Fa 265302	7.3125	N	S
155	156	0	1		Williams, Mr. Charles Duane	male	51.0	0	1	PC 17597	61.3792	N	C

156 rows × 12 columns

2. 파이썬 데이터 다루기

2.39 결측치를 평균값으로 변경하기

✓ 실행 코드

```
titanic_df_copy['age'].isnull( )
```

```
age
0    False
1    False
2    False
3    False
4    False
...     ...
151  False
152  False
153  False
154   True
155  False
156 rows × 1 columns
dtype: bool
```

2. 파이썬 데이터 다루기

2.39 결측치를 평균값으로 변경하기

✓ 실행 코드

```
titanic_df['age']=titanic_df_copy['age'].fillna(titanic_df_copy['age'].mean())  
titanic_df_copy['age']
```

age	
0	22.0
1	38.0
2	26.0
3	35.0
4	35.0
...	...
151	22.0
152	55.5
153	40.5
154	NaN
155	51.0

156 rows × 1 columns

dtype: float64

2. 파이썬 데이터 다루기

2.40 to_numeric

- 데이터형을 숫자형으로 바꿀 수 있음
- to_numeric 함수에는 errors 옵션 사용
 - errors='ignore': 숫자형으로 변경할 수 없는 데이터라면 원본 데이터 그대로 반환
 - errors='coerce': 숫자형으로 변경할 수 없는 데이터라면 기존 데이터는 지우고 NaN으로 설정하여 반환
 - errors='raise': 숫자형으로 변경할 수 없는 데이터라면 오류 발생으로 코드 중단
- dtypes를 실행하여 숫자형으로 잘 변경되었는지 확인

2. 파이썬 데이터 다루기

2.40 to_numeric

✓ 실행 코드

```
titanic_df1=titanic_df[['survived', 'pclass', 'name', 'sex',  
'age', 'sibsp', 'parch', 'fare']]  
titanic_df2=titanic_df1.apply(pd.to_numeric,  
errors='coerce')  
titanic_df2
```

	survived	pclass	name	sex	age	sibsp	parch	fare
0	0	3	NaN	NaN	22.000000	1	0	7.2500
1	1	1	NaN	NaN	38.000000	1	0	71.2833
2	1	3	NaN	NaN	26.000000	0	0	7.9250
3	1	1	NaN	NaN	35.000000	1	0	53.1000
4	0	3	NaN	NaN	35.000000	0	0	8.0500
...	...	...	...	...	...	...	...	...
151	1	1	NaN	NaN	22.000000	1	0	66.6000
152	0	3	NaN	NaN	55.500000	0	0	8.0500
153	0	3	NaN	NaN	40.500000	0	2	14.5000
154	0	3	NaN	NaN	28.141508	0	0	7.3125
155	0	1	NaN	NaN	51.000000	0	1	61.3792

156 rows × 8 columns

2. 파이썬 데이터 다루기

2.40 to_numeric

✓ 실행 코드

```
titanic_df2.dtypes
```

```
0
survived    int64
pclass      int64
name        float64
sex          float64
age          float64
sibsp        int64
parch        int64
fare         float64
dtype: object
```

2. 파이썬 데이터 다루기

2.41 astype 함수

- 원하는 데이터형으로 변경할 때 사용
- 데이터프레임 이름[열 이름].astype('변경할 데이터형')

✓ 실행 코드

```
titanic_df2['survived']=titanic_df2['survived'].astype('float')
titanic_df2['pclass']=titanic_df2['pclass'].astype('float')
titanic_df2['age']=titanic_df2['age'].astype('float')
titanic_df2['sibsp']=titanic_df2['sibsp'].astype('float')
titanic_df2['parch']=titanic_df2['parch'].astype('float')
titanic_df2['fare']=titanic_df2['fare'].astype('float')
titanic_df2.dtypes
```

	0
survived	float64
pclass	float64
name	float64
sex	float64
age	float64
sibsp	float64
parch	float64
fare	float64

dtype: object

2. 파이썬 데이터 다루기

2.42 숫자형 변수로 바꾸기

- 특정 열의 값을 데이터 분석에 사용할 수 있게 숫자형으로 변경 가능
- 예) titanic_df1에 gender 열을 추가하고 female은 0, male은 1로 표시
 - sex 열을 삭제한 뒤 head 함수로 첫 5행 확인하면 숫자로 변경 됨
 - info 함수로 gender열 확인

✓ 실행 코드

```
titanic_df1=titanic_df[['survived', 'pclass', 'name', 'sex',  
'age', 'sibsp', 'parch', 'fare']]  
tmp=[]  
for each in titanic_df1['sex']:  
    if each=='female':  
        tmp.append(0)  
    else:  
        tmp.append(1)  
  
titanic_df1['gender']=tmp  
titanic_df1
```


2. 파이썬 데이터 다루기

2.42 숫자형 변수로 바꾸기

```
/tmp/ipykernel_2842/525523475.py:9: SettingWithCopyWarning:  
A value is trying to be set on a copy of a slice from a DataFrame.  
Try using .loc[row_indexer,col_indexer] = value instead
```

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
titanic_df1['gender']=tmp

	survived	pclass	name	sex	age	sibsp	parch	fare	gender
0	0	3	Braund, Mr. Owen Harris	male	22.000000	1	0	7.2500	1
1	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.000000	1	0	71.2833	0
2	1	3	Heikkinen, Miss. Laina	female	26.000000	0	0	7.9250	0
3	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.000000	1	0	53.1000	0
4	0	3	Allen, Mr. William Henry	male	35.000000	0	0	8.0500	1
...	...	...	...	...	...	...	...	...	...
151	1	1	Pears, Mrs. Thomas (Edith Wearne)	female	22.000000	1	0	66.6000	0
152	0	3	Meo, Mr. Alfonzo	male	55.500000	0	0	8.0500	1
153	0	3	van Billiard, Mr. Austin Blyler	male	40.500000	0	2	14.5000	1
154	0	3	Olsen, Mr. Ole Martin	male	28.141508	0	0	7.3125	1
155	0	1	Williams, Mr. Charles Duane	male	51.000000	0	1	61.3792	1

156 rows × 9 columns

2. 파이썬 데이터 다루기

2.42 숫자형 변수로 바꾸기

✓ 실행 코드

```
titanic_df1.drop(columns='sex', inplace=True)
titanic_df1.head( )
```

/tmp/ipykernel_2842/2882126308.py:1: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
titanic_df1.drop(columns='sex', inplace=True)

	survived	pclass	name	age	sibsp	parch	fare	gender
0	0	3	Braund, Mr. Owen Harris	22.0	1	0	7.2500	1
1	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	38.0	1	0	71.2833	0
2	1	3	Heikkinen, Miss. Laina	26.0	0	0	7.9250	0
3	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	35.0	1	0	53.1000	0
4	0	3	Allen, Mr. William Henry	35.0	0	0	8.0500	1

2. 파이썬 데이터 다루기

2.42 숫자형 변수로 바꾸기

✓ 실행 코드

```
titanic_df1.info( )
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 156 entries, 0 to 155  
Data columns (total 8 columns):  
#   Column      Non-Null Count  Dtype  
---  -  
0   survived    156 non-null    int64  
1   pclass      156 non-null    int64  
2   name        156 non-null    object  
3   age         156 non-null    float64  
4   sibsp       156 non-null    int64  
5   parch       156 non-null    int64  
6   fare        156 non-null    float64  
7   gender      156 non-null    int64  
dtypes: float64(2), int64(5), object(1)  
memory usage: 9.9+ KB
```

2. 파이썬 데이터 다루기

2.43 문자형 변수를 명목 변수화하기

- 예) 승객의 호칭으로 4개의 그룹 만들기

- ① 특별한 지위(Master, Don, Rev)를 나타내는 호칭을 모두 Special로 바꾼 후, Mr, Mrs, Miss, Special로 4개 값을 갖는 title 열 생성
 - unique와 len 함수를 사용하여 title 열의 값 확인 가능
 - 사용하지 않는 name 열은 삭제
- ② 호칭 중 Special은 1, 나머지는 0으로 바꾼 뒤 이 열을 special_title로 나타냄
- ③ title 열 삭제

✓ 실행 코드

```
condition=lambda x: x.split(',')[1].split('.')[0].strip()  
titanic_df1['title']=titanic_df1['name'].map(condition)  
titanic_df1['title'].unique()
```

```
/tmp/ipykernel_2842/3556170199.py:2: SettingWithCopyWarning:  
A value is trying to be set on a copy of a slice from a DataFrame.  
Try using .loc[row_indexer,col_indexer] = value instead
```

```
See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy  
titanic_df1['title']=titanic_df1['name'].map(condition)  
array(['Mr', 'Mrs', 'Miss', 'Master', 'Don', 'Rev'], dtype=object)
```

2. 파이썬 데이터 다루기

2.43 문자형 변수를 명목 변수화하기

✓ 실행 코드

```
Special=['Master', 'Don', 'Rev']
for each in Special:
    titanic_df1['title']=titanic_df1['title'].replace(each,
'Special')

titanic_df1['title'].unique( )
titanic_df1
```

	survived	pclass	name	age	sibsp	parch	fare	gender	title
0	0	3	Braund, Mr. Owen Harris	22.000000	1	0	7.2500	1	Mr
1	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	38.000000	1	0	71.2833	0	Mrs
2	1	3	Heikkinen, Miss. Laina	26.000000	0	0	7.9250	0	Miss
3	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	35.000000	1	0	53.1000	0	Mrs
4	0	3	Allen, Mr. William Henry	35.000000	0	0	8.0500	1	Mr
...	...	...	...	...	...	...	...	...	...
151	1	1	Pears, Mrs. Thomas (Edith Wearne)	22.000000	1	0	66.6000	0	Mrs
152	0	3	Meo, Mr. Alfonzo	55.500000	0	0	8.0500	1	Mr
153	0	3	van Billiard, Mr. Austin Blyler	40.500000	0	2	14.5000	1	Mr
154	0	3	Olsen, Mr. Ole Martin	28.141508	0	0	7.3125	1	Mr
155	0	1	Williams, Mr. Charles Duane	51.000000	0	1	61.3792	1	Mr

156 rows × 9 columns

2. 파이썬 데이터 다루기

2.43 문자형 변수를 명목 변수화하기

✓ 실행 코드

```
len(titanic_df1['title'].unique( ))
```

4

```
titanic_df1=titanic_df1.drop('name', axis=1)  
titanic_df1
```

	survived	pclass	age	sibsp	parch	fare	gender	title
0	0	3	22.000000	1	0	7.2500	1	Mr
1	1	1	38.000000	1	0	71.2833	0	Mrs
2	1	3	26.000000	0	0	7.9250	0	Miss
3	1	1	35.000000	1	0	53.1000	0	Mrs
4	0	3	35.000000	0	0	8.0500	1	Mr
...	...	...	...	...	...	...	...	...
151	1	1	22.000000	1	0	66.6000	0	Mrs
152	0	3	55.500000	0	0	8.0500	1	Mr
153	0	3	40.500000	0	2	14.5000	1	Mr
154	0	3	28.141508	0	0	7.3125	1	Mr
155	0	1	51.000000	0	1	61.3792	1	Mr

156 rows × 8 columns

2. 파이썬 데이터 다루기

2.43 문자형 변수를 명목 변수화하기

✓ 실행 코드

```
def convert_title(x):  
    if x=="Special":  
        return 1  
    else:  
        return 0
```

```
titanic_df1["special_title"]=titanic_df1["title"].apply(convert_title)  
titanic_df1.tail(7)
```

	survived	pclass	age	sibsp	parch	fare	gender	title	special_title
149	0	2	42.000000	0	0	13.0000	1	Special	1
150	0	2	51.000000	0	0	12.5250	1	Special	1
151	1	1	22.000000	1	0	66.6000	0	Mrs	0
152	0	3	55.500000	0	0	8.0500	1	Mr	0
153	0	3	40.500000	0	2	14.5000	1	Mr	0
154	0	3	28.141508	0	0	7.3125	1	Mr	0
155	0	1	51.000000	0	1	61.3792	1	Mr	0

2. 파이썬 데이터 다루기

2.43 문자형 변수를 명목 변수화하기

✓ 실행 코드

```
titanic_df1.drop('title', axis=1, inplace=True)
titanic_df1
```

	survived	pclass	age	sibsp	parch	fare	gender	special_title
0	0	3	22.000000	1	0	7.2500	1	0
1	1	1	38.000000	1	0	71.2833	0	0
2	1	3	26.000000	0	0	7.9250	0	0
3	1	1	35.000000	1	0	53.1000	0	0
4	0	3	35.000000	0	0	8.0500	1	0
...	...	...	...	...	...	...	...	...
151	1	1	22.000000	1	0	66.6000	0	0
152	0	3	55.500000	0	0	8.0500	1	0
153	0	3	40.500000	0	2	14.5000	1	0
154	0	3	28.141508	0	0	7.3125	1	0
155	0	1	51.000000	0	1	61.3792	1	0

156 rows × 8 columns



강남대학교
KANGNAM UNIVERSITY

감사합니다

